

2026年度

機械学習演習

第10回：次元削減（PCA とランダム射影）

計良 宥志

本日の内容

1. **なぜ次元削減か**：高次元の呪い・距離の集中
2. **全体像**：「埋め込みの目標」→「定式化」→「解」という設計図
3. **PCA**：分散最大の線形射影（固有値問題）
4. **集中不等式**：Markov / Chebyshev / Chernoff / Hoeffding
5. **ランダム射影と Johnson-Lindenstrauss の補題**
6. **演習**：PCA vs ランダム射影（距離保存・速度）

多様体学習（Isomap・LLE）は **第11回** で扱う。

1. なぜ次元削減か

高次元データと次元削減

現実のデータは高次元：

- 画像：256 × 256 ピクセル $\Rightarrow$ 65,536 次元
- テキスト：語彙数 10,000 $\Rightarrow$ 10,000 次元
- 遺伝子発現：数万次元

次元削減：本質的な情報をなるべく保ちながら，低次元の表現 $y_i \in \mathbb{R}^k$ ($k \ll n$) を得る.

- 可視化 ($k = 2, 3$) ・ 計算効率 ・ ノイズ除去 ・ 前処理

高次元の呪い：距離の集中

n 次元単位球面から一様ランダムに 2 点 x, y をとると,

$$\|x - y\|^2 = \|x\|^2 - 2x^\top y + \|y\|^2 = 2 - 2x^\top y$$

このとき $\mathbb{E}[x^\top y] = 0$, $\text{Var}(x^\top y) = \frac{1}{n}$ なので, $n \rightarrow \infty$ で $x^\top y \rightarrow 0$ (確率収束).

どの 2 点間の距離も **ほぼ $\sqrt{2}$** に集中: 「近い／遠い」の区別が消える.

- 距離に基づく解析 (k-NN・クラスタリング...) がそのままでは機能しない.
- $\Rightarrow$ データの**本質的な構造**を捉えた低次元表現がほしい.

全体像：「良い埋め込み」の設計図

次元削減の各手法は、共通して次の **3 段構成** でできている。

埋め込みの目標（何を保つか）

⇒ **定式化**（制約付き最小化・最大化）

⇒ **解**（固有値問題・最小二乗 = 微分から解ける）

手法	埋め込みの目標（何を保つか）	解の形
PCA	分散（線形射影で情報を保つ）	固有値問題
ランダム射影	全ペア距離（確率的に）	乱数のみ（最適化なし！）
Isomap（第11回）	多様体に沿った 測地距離	固有値問題（MDS）
LLE（第11回）	局所線形関係 （近傍の重み）	最小二乗 + 固有値問題

2. PCA（復習）

PCA：分散最大の線形射影

埋め込みの目標

1 本の軸への射影 $z_i = w^\top x_i$ で、データの**ばらつき**（分散）をなるべく失わない。

定式化 中心化済みのデータ行列を $X = (x_1, \dots, x_m)^\top$ とすると、射影後の分散は $\frac{1}{m} \|Xw\|^2 = \frac{1}{m} w^\top X^\top X w$. これを最大化（定数 $\frac{1}{m}$ は省略）：

$$\max_{w \in \mathbb{R}^n} w^\top X^\top X w \quad \text{s.t.} \quad \|w\|^2 = 1$$

- ノルム制約がないと w を大きくするだけで目的関数が発散（制約が本質）.
- この**制約付き最大化**は**固有値問題**に帰着する（→ 次の演習）.

線形代数の復習：Trace

定義 正方行列 $A \in \mathbb{R}^{n \times n}$ の対角成分の和： $\text{tr}(A) = \sum_{i=1}^n A_{ii}$.

性質

- 線形性： $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$, $\text{tr}(cA) = c \text{tr}(A)$
- 転置不変： $\text{tr}(A^\top) = \text{tr}(A)$
- 巡回性： $\text{tr}(AB) = \text{tr}(BA)$, $\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB)$
- スカラーは自分の trace： $x^\top A x = \text{tr}(x^\top A x) = \text{tr}(A x x^\top)$

行列での微分 ($\partial/\partial X$)

$$\frac{\partial}{\partial X} \text{tr}(A^\top X) = A, \quad \frac{\partial}{\partial X} \text{tr}(X^\top M X) = (M + M^\top) X \xrightarrow{M=M^\top} 2MX$$

演習：PCA と固有値問題（行列形式）

中心化済みのデータ行列を $X = (x_1, \dots, x_m)^\top \in \mathbb{R}^{m \times n}$ とする. PCAは射影後のデータの分散を最大化したい. いま k 本の射影方向を列に並べた $V = (v_1, \dots, v_k) \in \mathbb{R}^{n \times k}$ (正規直交 $V^\top V = I_k$) 時, 分散最大化は以下の通り.

$$\max_{V \in \mathbb{R}^{n \times k}} \text{tr}(V^\top X^\top X V) \quad \text{s.t.} \quad V^\top V = I_k$$

これが固有値問題 $X^\top X V = V \Lambda$ に帰着することを示せ.

演習：PCAと低ランク近似

中心化済みのデータ行列 $X = (x_1, \dots, x_m)^\top \in \mathbb{R}^{m \times n}$ の k ランク近似がPCAで実現されることを示せ.

$$\min_{V \in \mathbb{R}^{n \times k}} \|X - XVV^\top\|^2, \quad V^\top V = I_k.$$

PCAの限界

- PCA は**線形**な射影：データが**曲がった構造**（多様体）の上にあると，その構造は保てない $\Rightarrow$ **多様体学習へ（第11回）**.

3. 集中不等式

確率変数の性質

期待値 (線形性) $\mathbb{E}[aX + bY] = a \mathbb{E}[X] + b \mathbb{E}[Y]$

分散 $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

独立な場合 ($X \perp Y$)

$$\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y], \quad \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

$X_1, \dots, X_n$ を i.i.d. (平均 μ , 分散 σ^2) とする.

大数の法則 標本平均は真の平均に収束する : $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \mu.$

中心極限定理 和のばらつきは (スケールすると) 正規分布に近づく :

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n} \sigma} \xrightarrow{d} N(0, 1) \quad \left(\text{すなわち } \frac{1}{n} \sum_i X_i \approx N\left(\mu, \frac{\sigma^2}{n}\right) \right)$$

集中不等式：なぜ必要か

平均・分散がわかってても、「確率変数が**平均からどれだけ外れるか**」を直接おさえない。

集中不等式：確率変数が平均の近くに集中する（裾が小さい）ことを、確率の**上界**で保証する道具。

- 強さの順：**Markov**（仮定ゆるい・最弱） $\Rightarrow$ **Chebyshev** $\Rightarrow$ **Chernoff / Hoeffding**（指数的に強い）。
- いずれも本質は **Markov の不等式**から派生する。
- ランダム射影（JL の補題）の証明は、この**指数的な集中**が鍵。

Markov の不等式

非負の確率変数 $X \geq 0$ と任意の $a > 0$ に対して

$$\Pr(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

- 仮定は「**非負**」だけ（分散すら不要）。その分，上界はゆるい。
- すべての集中不等式の**出発点**。

Markov の不等式：証明

非負性より，任意の $a > 0$ について次の**指示関数の不等式**が成り立つ：

$$a \cdot \mathbf{1}\{X \geq a\} \leq X$$

($X \geq a$ なら左辺 $= a \leq X$ ，そうでなければ左辺 $= 0 \leq X$)．両辺の期待値をとると

$$a \Pr(X \geq a) = \mathbb{E}[a \mathbf{1}\{X \geq a\}] \leq \mathbb{E}[X]$$

$a > 0$ で割って $\Pr(X \geq a) \leq \mathbb{E}[X]/a$. ■

Markov の例：平均の何倍も超える確率

平均点 $\mathbb{E}[X] = 60$ 点 ($X \geq 0$) のテストで, 「90 点以上」の割合は？

$$\Pr(X \geq 90) \leq \frac{60}{90} = \frac{2}{3}$$

- 一般に「平均の c 倍以上」をとる確率は $\leq 1/c$ (例：平均の 3 倍以上は高々 $1/3$).
- 分布の形を一切仮定せず言える反面, 上界はかなりゆるい.

Chebyshev の不等式

平均 $\mu = \mathbb{E}[X]$, 分散 $\sigma^2 = \text{Var}(X)$ をもつ X と任意の $a > 0$ に対して

$$\Pr(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}$$

- 「平均からのずれ」を**分散**でおさえる.
- $a = t\sigma$ とおくと $\Pr(|X - \mu| \geq t\sigma) \leq 1/t^2$.

Chebyshev の不等式：証明

非負の確率変数 $(X - \mu)^2 \geq 0$ に **Markov の不等式** を a^2 で適用するだけ：

$$\Pr(|X - \mu| \geq a) = \Pr((X - \mu)^2 \geq a^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{a^2} = \frac{\sigma^2}{a^2}$$



- ポイント：**Markov** を $(X - \mu)^2$ に適用しただけ.

Chebyshev の例：大数の法則の定量版

i.i.d. $X_1, \dots, X_n$ (平均 μ , 分散 σ^2) の標本平均 $\bar{X} = \frac{1}{n} \sum_i X_i$. 独立性より $\text{Var}(\bar{X}) = \sigma^2/n$ なので,

$$\Pr(|\bar{X} - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

- これで**大数の法則** (標本平均 $\rightarrow$ 真の平均) が定量的に示せる.
- ただし n について $1/n$ (多項式) の減衰でしかない $\Rightarrow$ 次の Chernoff はもっと速い.

Chernoff 限界（指数モーメント法）

確率変数 X と任意の a に対して

$$\Pr(X \geq a) \leq \min_{\lambda > 0} e^{-\lambda a} \mathbb{E}[e^{\lambda X}]$$

- $M(\lambda) = \mathbb{E}[e^{\lambda X}]$ は**積率母関数** (MGF).
- **独立和** $S = \sum_i X_i$ では $\mathbb{E}[e^{\lambda S}] = \prod_i \mathbb{E}[e^{\lambda X_i}]$ と分解 $\Rightarrow$ **指数的に**小さい裾.
- Markov・Chebyshev より圧倒的に強い（多項式 $\rightarrow$ 指数）.

Chernoff 限界：証明

任意の $\lambda > 0$ について $e^{\lambda x}$ は単調増加なので、事象 $\{X \geq a\}$ と $\{e^{\lambda X} \geq e^{\lambda a}\}$ は同じ。非負の $e^{\lambda X}$ に **Markov の不等式** を適用：

$$\Pr(X \geq a) = \Pr(e^{\lambda X} \geq e^{\lambda a}) \leq \frac{\mathbb{E}[e^{\lambda X}]}{e^{\lambda a}} = e^{-\lambda a} \mathbb{E}[e^{\lambda X}]$$

これが任意の $\lambda > 0$ で成り立つので、右辺を λ について最小化すればよい。 ■

- またしても**本質は Markov**（今度は $e^{\lambda X}$ に適用）。

Chernoff の例：ガウスの裾

$Z \sim N(0, 1)$ の MGF は $\mathbb{E}[e^{\lambda Z}] = e^{\lambda^2/2}$. Chernoff 限界より

$$\Pr(Z \geq t) \leq \min_{\lambda > 0} e^{-\lambda t} e^{\lambda^2/2} = e^{-t^2/2} \quad (\lambda = t \text{ で最小})$$

- 標準正規の裾は t^2 で**指数的**に減衰 (Chebyshev の $1/t^2$ より遥かに速い).
- 同じ MGF の議論で $\sum_i Z_i^2$ (カイ二乗) の裾も評価できる $\Rightarrow$ **JL の補題の証明②**.

Hoeffding の不等式

独立な $X_1, \dots, X_n$ が $X_i \in [a_i, b_i]$ (**有界**) をみたすとき, $S = \sum_i X_i$ について

$$\Pr(S - \mathbb{E}[S] \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

- 仮定は「**有界**」だけで分布の形は不問. 両側なら確率は 2 倍.
- 証明は Chernoff 法 + **Hoeffding の補題** $\mathbb{E}[e^{\lambda(X - \mathbb{E}X)}] \leq e^{\lambda^2(b-a)^2/8}$ (今回は結果のみ).

Hoeffding の例：コイン・経験平均

$X_i \in [0, 1]$ i.i.d. (平均 μ) の標本平均 $\bar{X} = \frac{1}{n} \sum_i X_i$. 各 $(b_i - a_i) = 1$ なので

$$\Pr(|\bar{X} - \mu| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2)$$

- Chebyshev の $\sigma^2/(n\varepsilon^2)$ (多項式) に対し, n **について指数的**に小さい!
- 「 $\bar{X}$ を $\mu \pm \varepsilon$ に収めるのに必要な n 」は $O(\varepsilon^{-2} \log \frac{1}{\delta}) \Rightarrow \text{JL の } k = O(\varepsilon^{-2} \log m)$ と同じ匂い.

4. ランダム射影と JL の補題

高次元ベクトルの性質

ランダムな 2 本のベクトルは、高次元では**ほぼ直交**する。成分が i.i.d. (平均 0・分散 $1/n$) の $u, v \in \mathbb{R}^n$ を考える。

直交性は、なす角の余弦が小さくなることで分かる：

$$\cos \theta = \frac{u^\top v}{\|u\| \|v\|}$$

- **分子** (内積 $u^\top v$) は平均 0 のまわりに集中する (→ 内積の演習)。
- **分母** ($\|u\| \|v\|$) はほぼ一定 ≈ 1 になる (→ ノルムの演習)。

$\Rightarrow n \rightarrow \infty$ で $\cos \theta \rightarrow 0$, $\theta \rightarrow 90^\circ$ (**ほぼ直交**)。ランダム射影が効く直感。

演習：内積

前スライドの u, v （成分が i.i.d., 平均 0 ・分散 $1/n$ ）について、内積 $u^\top v$ の**期待値と分散**を求めよ.

演習：ノルム

前スライドの u について, 特に各成分が **ガウス** $N(0, 1/n)$ に従う場合を考える.
 $\mathbb{E}[\|u\|^2] = 1$ と $\text{Var}(\|u\|^2) = 2/n$ を示せ.

ヒント 平均 0 のガウスでは 4 次モーメントは $\mathbb{E}[u_i^4] = 3 (\mathbb{E}[u_i^2])^2$ となる.

ランダム射影：最適化しない次元削減

これまでの手法は、データから**最適**な埋め込みを計算した。逆の極端な発想：

ランダム射影：行列 $A \in \mathbb{R}^{k \times n}$ の各成分を乱数で生成し、 $f(x) = Ax$ で射影。

$$A_{ij} \sim N\left(0, \frac{1}{k}\right) \quad \text{i.i.d.}$$

- **データを一切見ない**（学習・最適化なし）。生成は $O(nk)$ で一瞬。
- PCA と正反対のアプローチ。こんなものが上手くいくのか？

驚くべき事実（JL の補題）： $k = O(\varepsilon^{-2} \log m)$ で、**全ペアの距離**が $1 \pm \varepsilon$ 倍の精度で保たれる。

Johnson-Lindenstrauss の補題

設定 $x_1, \dots, x_m \in \mathbb{R}^n$. $A \in \mathbb{R}^{k \times n}$, $A_{ij} \sim N(0, 1/k)$ i.i.d., $f(x) = Ax$.

補題 (Johnson-Lindenstrauss, 1984)

$0 < \varepsilon < 1$ とする. $k \geq 36 \varepsilon^{-2} \ln m$ ならば, 確率 $1 - \frac{1}{m}$ 以上で, **すべての** ペア (i, j) に対して

$$(1 - \varepsilon) \|x_i - x_j\|^2 \leq \|f(x_i) - f(x_j)\|^2 \leq (1 + \varepsilon) \|x_i - x_j\|^2$$

- 必要な次元 k は $\log m$ のオーダーで, **元の次元 n に依存しない**.
- 定数 36 は証明を簡単にするためのもの (最適ではない).

証明は 3 ステップ: ① 期待値の保存 ② 集中不等式 ③ union bound

証明 ①：ノルムは期待値では保たれる

単位ベクトル $u \in \mathbb{R}^n$ ($\|u\| = 1$) を固定する. 射影の第 i 成分は

$$Y_i := (Au)_i = \sum_{j=1}^n A_{ij} u_j \sim N\left(0, \sum_j \frac{u_j^2}{k}\right) = N\left(0, \frac{1}{k}\right)$$

(独立なガウスの線形結合はガウス). 行が独立なので $Y_1, \dots, Y_k$ は i.i.d.,
 $Z_i := \sqrt{k} Y_i \sim N(0, 1)$ とおくと,

$$\|Au\|^2 = \sum_{i=1}^k Y_i^2 = \frac{1}{k} \sum_{i=1}^k Z_i^2, \quad \mathbb{E}[\|Au\|^2] = \frac{1}{k} \cdot k = 1 = \|u\|^2$$

期待値ではノルムが保存. 次に「ばらつきが小さい」ことを示す (発展編).

証明 ②：集中不等式（Chernoff でカイ二乗の裾）

$\|Au\|^2 = \frac{1}{k} \sum_{i=1}^k Z_i^2$ (Z_i i.i.d. $N(0, 1)$) の裾を, 先に学んだ **Chernoff 法** で評価する. カイ二乗の MGF は $\mathbb{E}[e^{\lambda Z_i^2}] = (1 - 2\lambda)^{-1/2}$ ($\lambda < \frac{1}{2}$) なので, 独立和の分解 $\prod_i$ より

$$\Pr\left(\sum_i Z_i^2 \geq (1 + \varepsilon)k\right) \leq \min_{0 < \lambda < 1/2} e^{-\lambda(1+\varepsilon)k} (1 - 2\lambda)^{-k/2}$$

$\lambda = \frac{\varepsilon}{2(1+\varepsilon)}$ を代入して整理し, 下側も同様に評価すると

$$\Pr\left(\left|\|Au\|^2 - 1\right| \geq \varepsilon\right) \leq 2 \exp\left(-\frac{k\varepsilon^2}{12}\right)$$

- **Chernoff のテンプレ通り** : MGF を計算 $\rightarrow \lambda$ を最適化. 射影次元 k について**指数的に集中**.

証明 ③（発展編）：union bound で全ペアへ

各ペア (i, j) に対し単位ベクトル $u_{ij} = \frac{x_i - x_j}{\|x_i - x_j\|}$ をとると、線形性より

$$\frac{\|f(x_i) - f(x_j)\|^2}{\|x_i - x_j\|^2} = \|Au_{ij}\|^2$$

①② より、1 ペアが $1 \pm \varepsilon$ から外れる確率は $\leq 2e^{-k\varepsilon^2/12}$. ペア数は $\binom{m}{2} \leq \frac{m^2}{2}$ なので、

$$\Pr(\text{どこかのペアで失敗}) \leq \frac{m^2}{2} \cdot 2e^{-k\varepsilon^2/12} = m^2 e^{-k\varepsilon^2/12} \leq m^2 \cdot m^{-3} = \frac{1}{m}$$

最後の不等式で $k \geq 36 \varepsilon^{-2} \ln m$ を使った. ■

- **ポイント**：必要な次元 $k = O(\varepsilon^{-2} \log m)$ は、元の次元 n に**一切依存しない**.

PCA vs ランダム射影

	PCA	ランダム射影
射影の作り方	共分散行列の固有ベクトル	ガウス乱数
データ依存性	依存（データから学習）	非依存 （データを見ない）
保つもの	分散（大域的な構造）	全ペアの距離 （確率的に $1 \pm \varepsilon$ ）
必要な次元 k	データ次第（寄与率で判断）	$O(\varepsilon^{-2} \log m)$, n に無関係
計算	固有値分解 / SVD	乱数生成のみ
保証	データに低次元構造があれば強い	データによらず 常に 成立

低次元構造があるなら PCA, 超高次元・大規模で「とにかく距離を保って圧縮」ならランダム射影.

5. 演習

演習：PCA vs ランダム射影

課題1 `sklearn.datasets.load_digits` (64 次元) で, PCA とランダム射影の**距離の保存**を比較せよ.

1. $k \in \{2, 5, 10, 20, 40\}$ について, PCA による射影と, ガウスランダム射影 $A_{ij} \sim N(0, 1/k)$ による射影をそれぞれ計算せよ.

2. ランダムに選んだ 200 点の全ペアについて距離比 $\frac{\|f(x_i) - f(x_j)\|}{\|x_i - x_j\|}$ を計算し, k ごとに箱ひげ図で比較せよ.

ヒント (有用な関数)

`np.linalg.eigh` / `scipy.spatial.distance.pdist` / PCA

演習：PCA vs ランダム射影（速度比較）

課題2 次元 n が十分大きい場合の **計算時間** を PCA とランダム射影で比較せよ.

1. 合成データ $X \in \mathbb{R}^{m \times n}$ (例: $m = 2000$, $n \in \{1000, 5000, 10000, 50000\}$) を `np.random.randn` 等で生成せよ.
2. 目標次元 $k = 50$ への射影を, (a) PCA (`PCA(n_components=k)`), (b) ガウスランダム射影 ($A \in \mathbb{R}^{k \times n}$ を生成し $XA^\top$) の 2 通りで計算し, それぞれの**実行時間**を `time.perf_counter` で計測せよ.
3. 横軸 n ・縦軸 実行時間 (対数軸) でプロットし, 両者の n に対するスケーリングを比較せよ.

課題

- 演習（課題1・課題2）を Moodle で提出（IPython Notebook 形式）.
- 課題1の比較図, 課題2の速度プロットを含めること.

