

2026年度

機械学習演習

第11回：多様体学習 (Isomap・LLE)

計良 宥志

本日の内容

1. **多様体仮説**：データは曲がった低次元構造の上にある
2. **Isomap**：測地距離を保つ（MDS → 固有値問題）
3. **LLE**：局所線形関係を保つ（最小二乗 + 固有値問題）
4. **3 手法の対比**（PCA / Isomap / LLE）
5. **演習**：LLE のスクラッチ実装

復習：線形次元削減（PCA）の限界

前回（第10回）：PCA は分散最大の**線形**射影 $\Rightarrow$ 固有値問題 $X^T X V = V \Lambda$.

- データが**曲がった構造**（多様体）の上にあると、線形射影では構造を保てない.
- $\Rightarrow$ 非線形な次元削減 = **多様体学習**へ.


共通の設計図：**埋め込みの目標**（何を保つか） $\Rightarrow$ **定式化**（制約付き最適化） $\Rightarrow$ **解**（固有値問題・最小二乗）

- 今回は「何を保つか」が異なる 2 手法（Isomap・LLE）を扱う.

1. 多様体仮説

多様体仮説：データは曲がった低次元構造の上にある

多様体仮説：高次元データは，実は**低次元の曲がった面**（多様体）の近くに分布していることが多い（例：スイスロール）。



- **ユークリッド距離**（赤）は隣の層へショートカットしてしまう。意味があるのは**多様体に沿った距離＝測地距離**（青）。

2. Isomap

Isomap：測地距離を保つ

埋め込みの目標

多様体に沿った**測地距離**を，低次元でもそのまま保ちたい（大域構造重視）.

測地距離の近似（グラフで）

1. 各点を k 近傍グラフで結ぶ（辺の重み＝ユークリッド距離）.
2. グラフ上の**最短経路距離** D_{ij} を計算（Dijkstra 法など）.
 - 近距離ではユークリッド距離が信頼できる $\Rightarrow$ それを**つなぎ合わせて**測地距離を近似.
 - 前々回（スペクトルクラスタリング）と同じく「**データ** $\rightarrow$ **グラフ**」の発想.

Isomap : 定式化 (アイディア)

アイディア. 測地距離 D_{ij} を, 低次元のユークリッド距離 $\|y_i - y_j\|$ でそのまま再現したい. 素直に書くと**距離を合わせる最小化問題** :

$$\min_{y_1, \dots, y_m \in \mathbb{R}^k} \sum_{i,j} (\|y_i - y_j\| - D_{ij})^2$$

- だが $\|y_i - y_j\|$ は y について**非線形**で, このままでは直接解けない.
- $\Rightarrow$ **距離を内積に変換**して, 線形代数 (固有値問題) に持ち込む.

Isomap : 工夫 (距離 → 内積)

仮定 埋め込み空間は**中心化されたユークリッド空間** ($\sum_i y_i = 0$, すなわち $\mathbf{1}^\top Y = 0$) で, 測地距離 D_{ij} を実現しているとする.

ポイント1. ユークリッド空間なので

$$D_{ij}^2 \approx \|y_i - y_j\|^2 = \|y_i\|^2 + \|y_j\|^2 - 2y_i^\top y_j$$

ポイント2. 二乗距離行列 $D^{(2)} = (D_{ij}^2)$ を書き下すと, $s = (s_i)_i = (\|y_i\|^2)_i$ として

$$D^{(2)} \approx s\mathbf{1}^\top + \mathbf{1}s^\top - 2YY^\top$$

中心化行列 $H = I - \frac{1}{m}\mathbf{1}\mathbf{1}^\top$ ($H\mathbf{1} = \mathbf{0}$) を左右から掛けると $s\mathbf{1}^\top$, $\mathbf{1}s^\top$ の項が消え, **中心化されているので** $HY = Y$ より

$$B := -\frac{1}{2} HD^{(2)} H \approx HYY^\top H = YY^\top$$

従って, D から B を計算し, その k ランク近似 Y を得れば良い.

Isomap : 定式化と解

$$\min_{Y \in \mathbb{R}^{m \times k}} \| B - YY^{\top} \|_F^2$$

PCA と同様, 上位 k 個の固有値の固有ベクトル (を固有値でスケールしたもの) が解.

$$B = V\Lambda V^{\top} = (V\sqrt{\Lambda})(V\sqrt{\Lambda})^{\top}$$

ここで, V と Λ を上位 k に削ったものを Y とするのが最適.

3. LLE

LLE：局所線形関係を保つ

埋め込みの目標

多様体は**局所的には平ら**（線形） $\Rightarrow$ 各点 x_i は近傍点の**重み付き平均**でよく再構成できる：

$$x_i \approx \sum_{j \in N(i)} w_{ij} x_j, \quad \sum_j w_{ij} = 1$$

- この**重み** w_{ij} （局所的な幾何の情報）を，低次元でもそのまま保ちたい.
- Isomap は**大域**（測地距離）保存 vs LLE は**局所**（近傍との線形関係）保存.
- 手順は 2 段階：**Step 1** 重みを求める（最小二乗） $\rightarrow$ **Step 2** 埋め込みを求める（固有値問題）.

LLE : 定式化 Step 1 (重み = 制約付き最小二乗)

各点 i ごとに, 再構成誤差を最小にする重みを求める:

$$\min_w \left\| x_i - \sum_{j \in N(i)} w_j x_j \right\|^2 \quad \text{s.t.} \quad \sum_{j \in N(i)} w_j = 1$$

制約 $\sum_j w_j = 1$ を使うと, **局所グラム行列** $C_{jl} = (x_i - x_j)^\top (x_i - x_l)$ で書き直せる:

$$\left\| \sum_j w_j (x_i - x_j) \right\|^2 = w^\top C w \implies \min_w w^\top C w \quad \text{s.t.} \quad \mathbf{1}^\top w = 1$$

- これは**制約付き最小二乗** $\Rightarrow$ 閉形式の解がある ($\rightarrow$ 次の演習).

演習：LLE の重み

C を正定値な対称行列とする．制約付き最小化

$$\min_w w^\top C w \quad \text{s.t.} \quad \mathbf{1}^\top w = 1$$

の解が次の閉形式で与えられることを，ラグランジュの未定乗数法を用いて示せ．

$$w = \frac{C^{-1} \mathbf{1}}{\mathbf{1}^\top C^{-1} \mathbf{1}}$$

LLE : 定式化 Step 2 (埋め込み = 固有値問題)

重み $W = (w_{ij})$ を**固定**し, 同じ線形関係が成り立つ低次元座標を探す (1 次元の場合) :

$$\min_{y \in \mathbb{R}^m} \sum_i \left(y_i - \sum_j w_{ij} y_j \right)^2 = y^\top M y, \quad M = (I - W)^\top (I - W)$$

自明解 ($y = \mathbf{0}$ や $y = \mathbf{1} : M\mathbf{1} = \mathbf{0}$) を避けるため, 制約を課す :


$$\min_y y^\top M y \quad \text{s.t.} \quad \|y\|^2 = m, \quad y^\top \mathbf{1} = 0$$

- 従って, y を 2 番目に小さい固有値の固有ベクトルにとれば最適.
- k 次元埋め込みなら, 小さい方から k 本 (定数ベクトルを除く).
- **スペクトルクラスタリングと全く同じ構図** ($v^\top L v$ の最小化 $\rightarrow$ 固有値問題) !

4. 3 手法の対比


3 手法の対比：着想

PCA



keep **variance**
(global, linear)


Isomap



keep **geodesic distance**
(global, nonlinear)

LLE

$$x_i \approx \sum_j w_{ij} x_j$$



keep **local linear relation**
(local, nonlinear)

- **PCA**：ばらつき最大の**直線方向**を残す（線形・大域）.
- **Isomap**：多様体に**沿った距離**を保って広げる（非線形・大域）.
- **LLE**：各点と**近傍の線形関係**だけを保つ（非線形・局所）.

3 手法の対比：定式化

	PCA	Isomap	LLE
埋め込みの目標	分散を保つ	測地距離を保つ	局所線形関係を保つ
定式化	$\max w^\top X^\top X w$ s.t. $\ w\ ^2 = 1$	$\ y_i - y_j\ \approx D_{ij}$ (MDS)	$\min w^\top C w, \mathbf{1}^\top w = 1$ $\min y^\top M y, y \perp \mathbf{1}$
解	$X^\top X$ の 最大 固有ベクトル	B の 上位 k 固有対	M の 下位 k 固有ベクトル
構造	線形・大域	非線形・大域	非線形・局所

どの手法も「**目標** → **制約付き最適化** → **固有値問題・最小二乗**」という同じ設計図. 違うのは「**何を保つか**」という思想だけ.

5. 演習

演習：LLE の実装

課題1 `sklearn.datasets.make_swiss_roll` ($m = 1000$, `noise=0.05`) に対し, LLE をスクラッチ実装せよ.

1. 各点の k 近傍を求める ($k = 10$ 程度, `sklearn.neighbors.NearestNeighbors` を使ってよい).
2. 各点 i について局所グラム行列 C を作り, 重み $w = \frac{C^{-1}\mathbf{1}}{\mathbf{1}^\top C^{-1}\mathbf{1}}$ を計算して W を構成せよ (数値安定化のため $C \leftarrow C + 10^{-3} \text{tr}(C) I$ としてよい).
3. $M = (I - W)^\top (I - W)$ を `np.linalg.eigh` で固有値分解し, **小さい方から 2, 3 番目**の固有ベクトル (定数ベクトルは除く) で 2 次元埋め込みを作れ.
4. 元の 3 次元データと埋め込み結果を, 多様体上の位置 (`make_swiss_roll` の返り値 `t`) で色付けして並べてプロットせよ.
5. `sklearn.manifold.LocallyLinearEmbedding` の結果と比較せよ.

課題

- 演習（課題1）を Moodle で提出（IPython Notebook 形式）.
- 課題1の埋め込みプロットを含めること.

