

2026年度

機械学習演習

第12回：強化学習（MDP・ベルマン方程式・価値反復）

計良 宥志

本日の内容

1. **MDP と価値関数**（機械学習Iの復習＋記号の整理）
2. **ベルマン方程式**：直感ではなく**導出**から理解する
3. **方策反復**（policy iteration）：評価して改善する
4. **価値反復**（value iteration）：最適価値を直接反復する
5. **演習**：マッチングアプリ（手計算）／グリッドワールド（実装）

1. MDP と価値関数

復習：強化学習の枠組み

エージェントが環境と相互作用し、**長期的な報酬の和**を最大化する.

各時刻 t : 状態 S_t を観測 $\rightarrow$ 行動 A_t を選択 $\rightarrow$ 報酬 R_{t+1} を受け取り次状態 S_{t+1} へ遷移.

環境は **MDP** (マルコフ決定過程) として定式化する :

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma)$$

- $\mathcal{S}$: 状態空間, $\mathcal{A}$: 行動空間
- $P(s' \mid s, a)$: 状態遷移確率, $r(s, a, s')$: 即時報酬, $\gamma \in [0, 1)$: 割引率

復習：マルコフ性と方策

マルコフ性：次状態は「現在の状態と行動」だけで決まる（過去の履歴は不要）.

$$P(S_{t+1} \mid S_t, A_t, S_{t-1}, \dots, S_0) = P(S_{t+1} \mid S_t, A_t)$$

方策 π ：状態から行動の選び方.

$$\pi(a \mid s) = \mathbb{P}(A_t = a \mid S_t = s) \quad (\text{決定論的なら } a = \pi(s))$$

強化学習の目標：**期待リターンを最大化する方策 π^*** を見つけること.

復習：リターン（割引報酬和）

時刻 t 以降に得られる割引報酬和を**リターン**と呼ぶ：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

- γ は遠い未来の報酬を割り引く（ $\gamma \rightarrow 0$ で近視眼的, $\gamma \rightarrow 1$ で先見的）.
- $\gamma < 1$ なら報酬が有界でも G_t は有限に収まる（収束のための重要な仮定）.

重要： $r(s, a, s')$ は**1 ステップの即時報酬**, G_t は**未来全体の割引和**. 混同しない.

復習：状態価値関数 V^π と行動価値関数 Q^π

方策 π のもとで,

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] \quad Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$$

- $V^\pi(s)$: 状態 s がどれくらい良いか.
- $Q^\pi(s, a)$: 状態 s で行動 a を取ることがどれくらい良いか.
- 行動選択には Q の方が直接使える ($\arg \max_a Q$ を選べばよい).

V と Q の関係

状態価値は行動価値の**方策による平均**. 最適価値では最良の行動を選ぶので **max** :

$$V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s, a), \quad V^*(s) = \max_a Q^*(s, a)$$

逆に, 行動価値は**1 ステップ先の状態価値**で書ける :

$$\begin{aligned} Q^\pi(s, a) &= \mathbb{E}_\pi [R_{t+1} + \gamma V^\pi(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^\pi(s')] \end{aligned}$$

2. ベルマン方程式

ベルマン方程式

状態価値 $V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$ は次の**ベルマン方程式**を満たす：

$$\begin{aligned} V^\pi(s) &= \mathbb{E}_\pi[R_{t+1} + \gamma V^\pi(S_{t+1}) \mid S_t = s] \\ &= \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^\pi(s')] \end{aligned}$$

意味は 今の状態の価値 = 今の報酬 + $\gamma \times$ 次の状態の価値 で、右辺に**同じ V^π 自身**が再帰的に現れる.

以下、リターンの分解 $G_t = R_{t+1} + \gamma G_{t+1}$ から出発して、この式を導く.

導出 ①：出発点はリターンの分解

リターンは「今の報酬」と「割引された次のリターン」に分解できる：

$$G_t = R_{t+1} + \gamma G_{t+1}$$

定義とこの分解から,

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s]$$

これを途中の確率変数 A_t, S_{t+1} で**場合分け**していく.

全期待値の公式

$$\mathbb{E}[X] = \sum_y \mathbb{P}(Y = y) \mathbb{E}[X \mid Y = y]$$

導出 ②：全期待値の公式で展開

$X = R_{t+1} + \gamma G_{t+1}$, $Y = (A_t, S_{t+1})$ で場合分けすると,

$$\begin{aligned} \mathbb{E}_\pi[X \mid S_t = s] \\ = \sum_a \sum_{s'} \mathbb{P}_\pi(A_t = a, S_{t+1} = s' \mid S_t = s) \mathbb{E}_\pi[X \mid S_t = s, A_t = a, S_{t+1} = s'] \end{aligned}$$

確率の部分は方策と遷移確率の積：

$$\mathbb{P}_\pi(A_t = a, S_{t+1} = s' \mid S_t = s) = \pi(a \mid s) P(s' \mid s, a)$$

右辺にまだ期待値が残る： a, s' を固定しても、その先の未来 $S_{t+2}, A_{t+1}, \dots$ はまだランダム.

導出 ③：なぜ右辺に $V^\pi(s')$ が出るのか

内側の期待値 $\mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a, S_{t+1} = s']$ を 2 つに分ける.

即時報酬 $\mathbb{E}[R_{t+1} \mid S_t = s, A_t = a, S_{t+1} = s'] = r(s, a, s').$

未来部分 マルコフ性より「 $S_{t+1} = s'$ さえ分かれば過去は無関係」:

$$\mathbb{E}_\pi[G_{t+1} \mid S_t = s, A_t = a, S_{t+1} = s'] = \mathbb{E}_\pi[G_{t+1} \mid S_{t+1} = s'] = V^\pi(s')$$

「次状態 s' 到達後の将来報酬の期待値」 = **まさに s' の価値 $V^\pi(s')$** .

導出 ④：状態価値のベルマン方程式

以上を組み合わせると，冒頭のベルマン方程式が得られる：

$$V^{\pi}(s) = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^{\pi}(s')]]$$

コンパクトには

$$V^{\pi}(s) = \mathbb{E}_{\pi} [R_{t+1} + \gamma V^{\pi}(S_{t+1}) \mid S_t = s]$$

演習：行動価値のベルマン方程式

行動価値関数 $Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$ について、状態価値と同じ要領で（リターンの分解 → 場合分け → マルコフ性）、次が成り立つことを示せ.

$$\begin{aligned} Q^\pi(s, a) &= \mathbb{E}_\pi[R_{t+1} + \gamma Q^\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a] \\ &= \sum_{s'} P(s' \mid s, a) \left[r(s, a, s') + \gamma \sum_{a'} \pi(a' \mid s') Q^\pi(s', a') \right] \end{aligned}$$

ヒント： $A_t = a$ は固定されているので最初の和 $\sum_a \pi(a \mid s)$ は不要. 次状態 s' に移った後は方策 π に従うため、 $V^\pi(s') = \sum_{a'} \pi(a' \mid s') Q^\pi(s', a')$ を使う.

計算メモ

3. 方策反復 (Policy Iteration)

Policy Evaluation : 方策を固定して価値を求める

方策 π を固定すると、遷移と報酬が**方策で平均された MDP** になる：

$$P^\pi(s' | s) = \sum_a \pi(a | s) P(s' | s, a), \quad r^\pi(s) = \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) r(s, a, s')$$

ベルマン方程式は**線形**になり、行列形式で書ける：

$$V^\pi = r^\pi + \gamma P^\pi V^\pi \implies (I - \gamma P^\pi) V^\pi = r^\pi$$

$\gamma < 1$ なら $I - \gamma P^\pi$ は正則 $\Rightarrow V^\pi = (I - \gamma P^\pi)^{-1} r^\pi$ (連立 1 次方程式で解ける).

Policy Improvement : 1 手だけ貪欲に改善

V^π が分かれば, 各状態で「最初の 1 手」を改善できる. 状態 s で行動 a を取る **1 ステップ先読み価値**は, 行動価値 Q^π そのもの:

$$Q^\pi(s, a) = \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^\pi(s')]$$

新しい方策を, これを最大化する貪欲方策とする:

$$\pi_{\text{new}}(s) = \arg \max_a Q^\pi(s, a)$$

「未来は今の π に任せ, 最初の 1 手だけ貪欲に取り替える」 $\Rightarrow$ 価値は必ず改善 (または不変).

Policy Iteration : 評価と改善の繰り返し

$$\pi_0 \xrightarrow{\text{評価}} V^{\pi_0} \xrightarrow{\text{改善}} \pi_1 \xrightarrow{\text{評価}} V^{\pi_1} \xrightarrow{\text{改善}} \pi_2 \rightarrow \dots$$

1. **評価** : 現在の π_k に対し V^{π_k} を求める (連立方程式).
2. **改善** : V^{π_k} に貪欲な π_{k+1} を作る.

有限 MDP $\cdot \gamma < 1$ では各状態で単調改善する :

$$V^{\pi_{k+1}}(s) \geq V^{\pi_k}(s) \quad (\forall s)$$

改善で作られる方策は**決定論的**で, その総数は $|\mathcal{A}|^{|S|}$ 個 (有限). 単調改善ゆえ
同じ方策は二度現れない $\Rightarrow$ **有限回**で最適方策 π^* に到達する.

4. 価値反復 (Value Iteration)

ベルマン最適方程式

最適価値関数は、「最良の行動を選ぶ」ので $\sum_a \pi$ が $\max_a$ に変わる：

$$V^*(s) = \max_a Q^*(s, a) = \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V^*(s')]]$$

ベルマン最適作用素 T を

$$(TV)(s) = \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V(s')]]$$

と定義すると、最適価値は T の**不動点**： $V^* = TV^*$.

Value Iteration の更新

適当な初期値 V_0 (例: $V_0 = 0$) から, 作用素 T を繰り返し当てる:

$$V_{k+1} = TV_k \iff V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V_k(s')]]$$

決定的環境 ($s' = f(s, a)$) なら, さらに簡単:

$$V_{k+1}(s) = \max_a [r(s, a, f(s, a)) + \gamma V_k(f(s, a))]$$

収束して V^* が求まれば, **各状態で $\arg \max$ を取るだけ**で最適方策が設計できる:

$$\pi^*(s) = \arg \max_a Q^*(s, a) = \arg \max_a \sum_{s'} P(s' | s, a) [r(s, a, s') + \gamma V^*(s')]]$$

反復中は方策を持たず価値だけ更新し, **最後に $\arg \max$ で方策を取り出す**.

Policy Iteration との違い

	Policy Iteration	Value Iteration
途中で持つもの	π_k と V^{π_k}	V_k のみ
方策は明示的か	はい	いいえ（必要なら後で取り出す）
途中の価値の意味	ある方策の価値 V^{π_k}	一般に $V_k \neq V^{\pi_k}$
1 反復のコスト	評価（連立方程式）が重い	1 回の max 掃引で軽い

価値反復でも各時点で貪欲方策 $\pi_k(s) = \arg \max_a [\dots]$ を取り出せるが、途中では一般に $V_k \neq V^{\pi_k}$.

なぜ収束するのか：縮小写像

$\gamma < 1$ のとき、ベルマン最適作用素 T は**縮小写像**（係数 γ ，最大値ノルム）：

$$\|TV - TW\|_{\infty} \leq \gamma \|V - W\|_{\infty}$$

- バナッハの不動点定理より，**唯一の不動点** V^* が存在し，任意の V_0 から $V_k \rightarrow V^*$
- 誤差は反復ごとに γ 倍に縮む（**幾何級数的に収束**）。

得られた V^* に貪欲な方策が最適方策 π^* ：

$$\pi^*(s) \in \arg \max_a Q^*(s, a) = \arg \max_a \sum_{s'} P(s' \mid s, a) [r(s, a, s') + \gamma V^*(s')]$$

一見すべて解けそうだが…現実の難しさ

1 状態の更新は簡単に見える。しかし現実の問題では：

- **全状態を列挙できない**：将棋・囲碁・ロボットでは状態数が膨大.
- **$V(s)$ を表で持てない**：連続・巨大状態空間 $\Rightarrow V_\theta(s), Q_\theta(s, a)$ を関数近似 (NN).
- **遷移 P が未知**：式の $\sum_{s'} P(s' | s, a)$ が計算できない $\Rightarrow$ サンプル (s, a, r, s') から学習.
- **報酬が疎い**：終端でしか報酬が出ない $\Rightarrow$ credit assignment 問題.
- **探索が必要**：良い行動を知るには試すしかない $\Rightarrow$ exploration-exploitation.

これらが「深層強化学習」へつながる動機。今回の演習は**表で持てる小さな MDP**で本質を掴む。

5. 演習

演習1（手計算）：マッチングアプリ

毎ステップ、プロフィールが1人表示される。相性は3段階：

$$\mathcal{S} = \{\text{High, Medium, Low}\}, \quad \mathcal{A} = \{\text{Like, Skip}\}$$

Like はコスト -1 。マッチすれば報酬が入る。Skip の即時報酬は 0 。

状態	マッチ確率	マッチ報酬	Like の期待即時報酬 $r(s, \text{Like})$
High	0.5	10	$0.5 \cdot 10 - 1 = 4$
Medium	0.2	6	$0.2 \cdot 6 - 1 = 0.2$
Low	0.05	2	$0.05 \cdot 2 - 1 = -0.9$

演習1（手計算）：設定の続きと問題

次プロフィールの分布（行動によらない）：

$$P(\text{High}) = 0.2, \quad P(\text{Medium}) = 0.5, \quad P(\text{Low}) = 0.3, \quad \gamma = 0.9$$

問題

1. 各状態のベルマン最適方程式を書け（次分布が行動に依らないことを使い, $C = \sum_{s'} P(s') V^*(s')$ とおくと簡単になる).
2. 各状態の最適行動を求めよ.
3. C と $V^*(\text{High})$, $V^*(\text{Medium})$, $V^*(\text{Low})$ を求めよ.
4. $V^*(\text{Low})$ は大きいかわ小さいか, その意味を説明せよ.

計算メモ

演習2（実装）：グリッドワールドの定式化

3×3 グリッド. 状態は格子点, 行動は上下左右の移動ベクトル. ゴール $G = (3, 3)$, $\gamma = 0.9$.

$$\mathcal{S} = \{(i, j) : i, j \in \{1, 2, 3\}\}, \quad \mathcal{A} = \{\uparrow, \downarrow, \leftarrow, \rightarrow\} = \{(\pm 1, 0), (0, \pm 1)\}$$

遷移（決定的）：移動先が盤内なら進み, 盤外（壁）なら同じ場所に留まる.

報酬： G に入るときだけ 1. **終端**： G は吸収状態 ($V(G) = 0$).

$$f(s, a) = \begin{cases} s + a & (s + a \in \mathcal{S}) \\ s & (s + a \notin \mathcal{S}) \end{cases} \quad r(s, a, s') = \mathbf{1}[s' = G] = \begin{cases} 1 & (s' = G) \\ 0 & (\text{otherwise}) \end{cases}$$

演習2（実装）：課題

課題

1. 価値反復 $V_{k+1}(s) = \max_a [r + \gamma V_k(f(s, a))]$ を実装せよ（ G 以外の状態のみ更新し，終端 G は毎回 $V(G) = 0$ に固定する）.
2. $V_1, V_2, V_3, \dots$ を順に表示し，**価値がゴールから逆向きに伝播する**様子を観察せよ.
3. 収束した V^* と，貪欲方策（矢印）を可視化せよ.
4. 各状態でゴールまでの最短距離 d を使った理論値 $V^*(s) = \gamma^{d-1}$ と一致するか確認せよ.

課題

- 演習1（マッチングアプリ）：**計算用紙のスキャン**を PDF で提出.
 - Adobe Scan などのスマホアプリが便利.
 - 正しい導出・綺麗なまとめではなく、計算演習に取り組んだ証として提出.
 - 分かりやすいところに氏名を書くこと. ファイル名は実装演習と同様.
- 演習2（グリッドワールド）：Moodle で提出（IPython Notebook 形式）.
 - 価値の伝播の様子と、最終的な V^* ・貪欲方策の可視化を含めること.

付録：バナッハの不動点定理

付録：縮小写像とバナッハの不動点定理

完備距離空間 $(\mathcal{X}, d)$ 上の写像 $T : \mathcal{X} \rightarrow \mathcal{X}$ が**縮小写像**とは, ある $\gamma \in [0, 1)$ があって

$$d(Tx, Ty) \leq \gamma d(x, y) \quad (\forall x, y \in \mathcal{X})$$

バナッハの不動点定理 T が縮小写像なら, 不動点 $x^* = Tx^*$ が**唯一**存在し, 任意の初期値 x_0 から $x_{k+1} = Tx_k$ は x^* に収束する:

$$d(x_k, x^*) \leq \frac{\gamma^k}{1 - \gamma} d(x_1, x_0) \rightarrow 0$$

- 価値反復は $\mathcal{X} = \mathbb{R}^{|S|}$, $d(V, W) = \|V - W\|_\infty$, T =ベルマン最適作用素の場合.

付録：証明 ①（列がコーシー列になる）

反復列 $x_{k+1} = Tx_k$ を考える. まず隣接項の距離が**等比的に縮む**：

$$d(x_{k+1}, x_k) = d(Tx_k, Tx_{k-1}) \leq \gamma d(x_k, x_{k-1}) \leq \cdots \leq \gamma^k d(x_1, x_0)$$

三角不等式と等比級数 ($m > k$) より,

$$d(x_m, x_k) \leq \sum_{i=k}^{m-1} d(x_{i+1}, x_i) \leq \sum_{i=k}^{m-1} \gamma^i d(x_1, x_0) \leq \frac{\gamma^k}{1 - \gamma} d(x_1, x_0)$$

$\gamma < 1$ より右辺は $k \rightarrow \infty$ で 0. ゆえに $\{x_k\}$ は**コーシー列**. 完備性から極限 $x^* = \lim_k x_k$ が存在する.

付録：証明 ②（不動点であることと一意性）

不動点であること T は縮小写像ゆえ連続なので,

$$Tx^* = T\left(\lim_{k \rightarrow \infty} x_k\right) = \lim_{k \rightarrow \infty} Tx_k = \lim_{k \rightarrow \infty} x_{k+1} = x^*$$

一意性 x^*, y^* をともに不動点とすると,

$$d(x^*, y^*) = d(Tx^*, Ty^*) \leq \gamma d(x^*, y^*)$$

$(1 - \gamma) d(x^*, y^*) \leq 0$ かつ $1 - \gamma > 0$ より $d(x^*, y^*) = 0$, すなわち $x^* = y^*$.

収束評価 証明①の $d(x_m, x_k)$ の評価で $m \rightarrow \infty$ とすれば

$$d(x^*, x_k) \leq \frac{\gamma^k}{1 - \gamma} d(x_1, x_0). \quad \blacksquare$$

付録：ベルマン最適作用素が縮小写像であること

$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty$ を示す. 各状態 s で, $\max$ の差の評価

$$\left| \max_a g(a) - \max_a h(a) \right| \leq \max_a |g(a) - h(a)|$$

を使う ($g(a), h(a)$ は行動 a ごとの 1 ステップ先読み価値). 差を取ると $r(s, a, s')$ は打ち消し合い,

$$|(TV)(s) - (TW)(s)| \leq \max_a \sum_{s'} P(s' | s, a) \gamma |V(s') - W(s')| \leq \gamma \|V - W\|_\infty$$

最後は $\sum_{s'} P(s' | s, a) = 1$ を使った. s について最大を取れば

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty. \quad \blacksquare$$